Aalto-yliopisto
Perustieteiden korkeakoulu
Tietotekniikan koulutusohjelma

Videokoodauksen rinnakkaistaminen

Kandidaatintyö

17. helmikuuta 2013

Miro Nurmela

Aalto-yliopisto
Perustieteiden korkeakoulu
Tietotekniikan koulutusohjelma

KANDIDAATINTYÖN
TIIVISTELMÄ

Tekijä:	Miro Nurmela
Työn nimi:	Videokoodauksen rinnakkaistaminen
Päiväys:	17. helmikuuta 2013
Sivumäärä:	25
Pääaine:	Ohjelmistotekniikka
Koodi:	T3001
Vastuuopettaja:	Ma professori Tomi Janhunen
Työn ohjaaja(t):	TkT Vesa Hirvisalo (Tietotekniikan laitos)

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Avainsanat:	videokoodaus, enkoodaus, dekoodaus, transkoodaus, rinnakkaisohjelmointi, rinnakkainen videokoodaus, rinnakkaislaskenta
Kieli:	Suomi

Sisältö

1 Johdanto

DISCLAIMER V1: Huonoa, muistiinpanonomaista tekstiä. Tullaan parantamaan. **DISCLAIMER V2:** Perusasiat alkaa olla selitetty, joskin teksti on hiomatonta ja mitä luultavimmin täynnä kirjoitus- ja lyöntivirheitä.

2 Aiempi tutkimus ja taustaa

3 Videokoodaus

Viimeisen viidentoista vuoden aikana suurin osa videodatasta on muuttunut analogisesta digitaaliseksi. VHS-kaseteista ja analogisista TV-lähetyksistä on siirrytty Blu-Ray -tekniikoihin, kännykkäkameroihin teräväpiirtotelevisioihin. Tekniikan kehitys ei näy ainoastaan tallennusmedioissa, sillä niin ikään tiedonsiirto on kehittynyt ja muuttunut monin paikoin langattomaksi.(Richardson (2010)) Videodatan määrä on myös valtavassa kasvussa (Cisco (2013), YouTube (2013)). Raaka videodata suuret määrät tallennustilaa eikä sen siirtäminen langattomasti ole mahdollista - tarvitaan siis teknologia, jolla videodataa pakataan ja puretaan (enkoodataan ja dekoodataan). Tätä pakkaamisen ja purkamisen prosessia kutsutaan videokoodaukseksi. Pakkaamisen ja purkamisen lisäksi videokoodaus kattaa myös signaalin reaaliaikaisesta kääntämisestä (transkoodaus). Transkoodaus tarkoittaa esimerkiksi enkoodatun datan kääntämistä toiseen koodausstandardiin (Angelides ja Agius (2011)). Seuraavissa alaluvuissa käsitellään videokoodausmenetelmien perusteita. Tästä lähin näihin viitataan termein enkoodaus, dekoodaus ja transkoodaus. Toinen kirjallisuudessa esiintyvä ja tärkeä termi on CODEC (COder DECOder pair), joka viittaa videokoodausta suorittavaan ohjelmistoon tai laitteeseen(Richardson (2010)).

Seuraavissa alaluvuissa käsitellään videokoodauksen peruskäsitteitä.

3.1 Videokoodauksen peruskäsitteet

3.1.1 Videokuvan esittäminen ja tallentaminen, diskreetti kosinimuunnos

Havaitsemamme maailma on jatkuva ja täynnä erilaisia kohteita, joilla on erilaisia ominaisuuksia (muoto, syvyys, tekstuuri, väri, valotiheys...) ja joita videolle haluttaisiin tallentaa. Maailma on niin niin ikään jatkuva, mitä esimerkiksi digitaalinen maailma ei ole. Jotta kameralla tai vastaavalla laitteella voitaisiin tallentaa esitys maailmasta, täytyy havainnot käsitellä ja tallentaa digitaaliseen maailmaan sopivaksi. Tässä luvussa käsitellään erialisia keinoja tallentaa videodataa - otantoja, ennustamista, väriavaruuksia ja näihin liittyviä matemaattisia tekniikoita ja käsitteitä.

Videodataa varten maailmasta täytyy kerätä äytteitä eri ajanhetkiltä. Otanta tapahtuu kahdessa ulottuvuudessa, ajassa ja tilassa (temporal and spatial sampling). Tyypillisesti tilaotokset ovat suorakaiteen muotoisia kuvia maailmasta, kun ajallinen otanta koostuu peräkkäisistä tilaotoksista. Tilaotokset koostuvat neliönmuotoisista kuvapisteistä eli pikseleistä, jotka on järjestetty ruudukoksi. Tilaotoksia peräkkäin toistamalla saadaan aikaan vaikutelma elävästä kuvasta. Tällainen data (käsittelemättömät aika- ja tilanäytteet) tunnetaan myös raakadatana. (Richardson (2010))

Jokaisen tilanäytteen kuvapisteeseen tallennetaan pisteeseen liittyvät tiedot. Yksinker-

taisinta kuvaa eli mustavalkokuvaa varten riittää esimerkiksi tallentaa vain yksi arvo kuvapisteestä (kirkkaus tai valotiheys), mutta värikuvassa täytyy tallentaa jokaisessa pisteessä esiintyvien värien määrä. Väriavaruudeksi kutsutaan menetelmää, joka on valittu kuvapisteiden kirkkauden, valotiheyden ja värin kuvaamiseksi. Värikuvan tallentamisessa suosittu tapa on RGB-väriavaruus. Tässä menetelmässä jokaisella kuvapisteellä on kolme parametria - punaisen, vihreän ja sinisen värin määrä. Edistyneemmät väriavaruudet hyödyntävät ihmisaivojen suurempaa herkkyyttä valotiheydelle kuin väreille (RGB-väriavaruudessa valotiheys ja väri ovat samanarvoisia tietoja). (Richardson (2010))

Avaruudellisia näytteitä voidaan ottaa joko peräkkäin (progressive) tai lomittain (interlacing). Peräkkäisessä otannassa jokaisella ajanhetkellä otetaan otos, johon tallennetaan käytössä olevan standardin mukainen määrä kuvapisteitä. Otosta kutsutaan ruuduksi (frame). Lomittaisessa otannassa taas jokaisella ajanhetkellä tallennetaan puolet standardin määräämistä kuvapisteistä, vaakasuunnassa joka toinen rivi siten, että peräkkäisillä ajanhetkillä tallennetaan lomittaiset rivit. Otosta kutsutaan kentäksi (field). Erotuksena näillä metodeilla on siinä, että lomittaisella otannalla syntyy pehmeämmin liikkuvaa kuvaa, kuin peräkkäisellä otosten määrän ollessa sama. Lomittamalla jokaiseen otokseen tallennetaan myös vähemmän tietoa. (Richardson (2010))

Kaikenlaiset pakkausmetodit (video, audio, kuvat) voidaan jakaa häviöttömiin ja häviöllisiin pakkausmetodeihin (lossy, lossless). Häviöttömissä metodeissa pakatusta datasta pystytään purkuvaiheessa palauttamaan täydellinen versio alkuperäisestä datasta, häviöllisessä pakkauksessa purettu versio on approksimaatio alkuperäisestä. On olemassa häviöttömiä videokoodausmenetelmiä, mutta pakkaussuhde jää liian alhaiseksi käytännön sovelluksiin. Häviölliset pakkausmenetelmät keskittyvät poistamaan datasta subjektiivista redundanssia, eli sellaisia yksityiskohtia, jota havainnoija ei kykene havaitsemaan. Näin saavutetaan huomattavasti tehokkaampia videokoodausmenetelmiä. (Richardson (2010))

Suurin osa videokoodausmenetelmistä hyödyntää videodatan vahvaa avaruudellista ja ajallista redundanssia. Käytännössä peräkkäisissä ruuduissa on suurella todennäköisyydellä lähes samat kuvapisteet (ajallinen) ja yhdessä ruudussa lähekkäiset kuvapisteet muistuttavat toisiaan suurella todennäköisyydellä. Monien CODECien ensimmäinen askel videon koodaamiseen on ennustaminen - jollakin määrällä edellisiä ajallisia näytteitä voidaan melko suurella todennäköisyydellä ennustaa, mitä tässä näytteessä tulee olemaan. Samaan tapaan saman näytteen sisällä jo käsiteltyjen kuvapisteiden perusteella ennustetaan tulevien kuvapisteiden laatua. Ennustuksilla voidaan vähentää tallennettavan datan määrää, kun purkuvaiheessa näytteitä pystytään uudelleenrakentamaan edellisten näytteiden perusteella. (Richardson (2010))

Ennen tallentamista tai siirtämistä videodataa useimmiten käsitellään vielä jollain tavalla ennustusten lisäksi. Tavoitteena on vähentää tallentamiseen tarvittavaa muistia ja helpottaa aikanaan tapahtuvaa dekoodausta. Tekniikoita on monia, mutta esitellään tässä

yleisin, eli diskreetti kosinimuunnos (Discrete Cosine Transformation, DCT).

DCT on Fourier-muunnoksen kaltainen muunnos, joka operoi $N \times N$ kokoisilla blokeilla avaruudellisissa näytteissä. Muunnos tuottaa niin ikään $N \times N$ kokoisen blokin, mutta kuvapisteiden arvojen sijaan uuden blokin arvot ovat kosinimuunnoksen perusblokkien suhteellisia voimakkuuksia koodattavassa olevassa blokissa. Kuvassa 1 on esitetty 8×8 -blokin DCT:n perusblokit. (Richardson (2010))

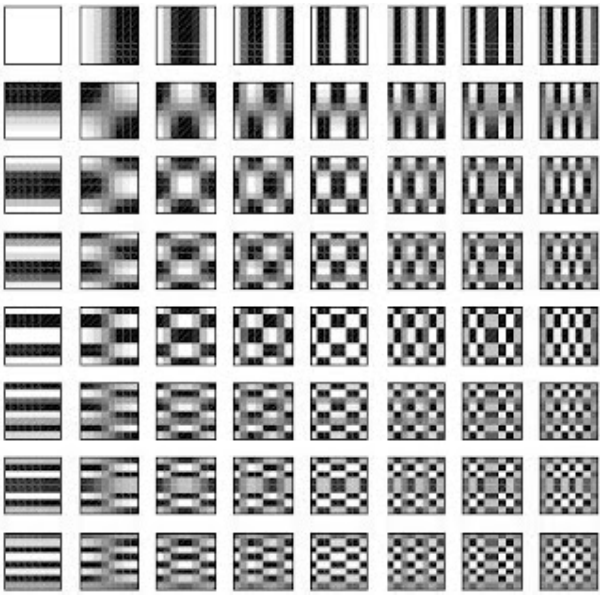

Kuva 1: 8×8 DCT:n perusblokit

DCT:n hyöty ei ole ilmeinen, sillä muunnos tapahtuu $N \times N$ -blokista $N \times N$ -blokkiin, eikä tässä säästetä lainkaan tilaa. Hyöty ilmenee purkuvaiheessa - on mahdollista purkaa DCT:n avulla tallennettua tietoa riittävän tarkaksi käyttämällä vain osaa DCT:n tuottamista suhteellisista voimakkuuksista. Voidaan siis tallentaa vain osa DCT:n tuottamista arvoista ja käyttää näin vähemmän tilaa tiedon tallentamiseen. Tyypillisesti käytetään DCT:n tuottamat suurimmat arvot (merkityksellisimmät perusblokit), jolloin harvinaisemmat ja räikeimmät erot jäävät puuttumaan lopullisesta kuvasta. Piirtämättä jäävät sellaiset yksityiskohdat, joita ihmissilmä on muutenkin heikko havaitsemaan. DCT:tä käyttävät koodausmenetelmät ovat siis pääosin häviöllisiä. (Richardson (2010))

DCT on Fourier-muunnoksen kaltainen muunnos, joka muuntaa videokoodauksen tapauksessa ruutujen näyteblokkien pikseliarvoja eri taajuuksilla värähteleviksi kosinifunktioiksi. Saavutettu etu on se, että häviöllisissä koodausmenetelmissä voidaan jättää koodaamatta pienet korkeataajuiset funktiot - niitä ihminen on huono huomaamaan. (Richardson (2010))

3.1.2 Videodatan matka lähteestä näyttölaitteelle, kuvadatan laadun mittarit

Videodata saa alkunsa lähteestä, joka on tyypillisesti kamera, joka tallentaa raakadatan. Tämän jälkeen suoritetaan CODEC suorittaa enkoodauksen, minkä jälkeen tiivistetty data voidaan tallentaa tai siirtää. Ketjun toisessa päässä on jälleen CODEC joka suorittaa tällä kertaa dekoodauksen ja esittää videon käyttäjälle. Kuva 2 havainnollistaa videodatan eri reittejä käyttäjälle ja toisaalta alleviivaa sitä, että kerran koodattu data on helppo siirtää ja se toimii erilaisissa ympäristöissä. (Richardson (2010))

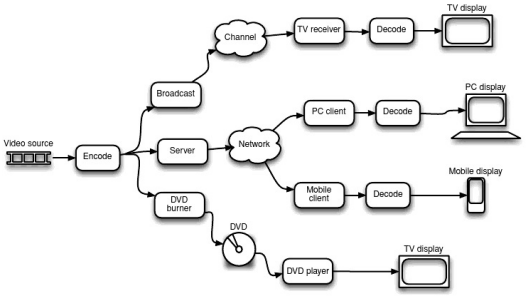

Kuva 2: Videokoodaus mahdollistaa datan liikkuvuuden

Koodauksen kolmas muoto, transkoodaus, tulisi tehdä, jos haluttu näyttölaite ei tuekaan sille tarjottua koodaustapaa.

Videodatan laatua voidaan mitata subjektiivisesti ja objektiivisesti. subjektiivinen mittaaminen on vaikeaa, sillä ihmisten arvioihin vaikuttavat monet seikat. Objektiivinen mittaaminen taas antaa selviä lukuja vastaukseksi, mutta tulosten merkitys ja vaikutus katsojakokemukseen on selvitettävä erikseen. Videodatan kohdalla subjektiivista mittaamista voidaan usein pitää tärkeämpänä kuin objektiivista, sillä tavoitteena usein on mahdollisimman miellyttävän katselukokemuksen tuottaminen käyttäjälle. Toisaalta videodatan objektiivinen laatu on erityistapauksissa myös tärkeää, esimerkiksi konenäköä hyödyntävissä sovelluksissa. (Richardson (2010))

Seuraavassa esitellään muutamia objektiivisia tapoja mitata videodatan laatua. Subjektiivinen mittaaminen perustuu lähinnä ihmisillä tehtyihin kyselytutkimuksiin, joilla on omat ongelmansa. Tässä työssä niihin ei keskitytä syvemmin.

Tiheys, jolla ruutuja tallennetaan, määrää ruutunopeuden (frame rate). Ruutunopeus ja kuvapisteiden määrä tarjoaa helpon mittarin kuvan laadulle. Normaalitarkkuuksinen ja korkeatarkkuuksinen (Standard Definition, High Definition) videodata eroavat toisistaan juuri kuvapisteiden määrän ja ruutunopeuden perusteella. Valittu ruutujen tai kenttien esitystapa vaikuttaa kuitenkin subjektiiviseen laatuun, joten ruutunopeuden ja kuvapisteiden määrää ei voi pitää ehdottomana laadun mittarina. (Richardson (2010))

Yleisesti käytetty mittari videodatan laadun mittaamiseen on PSNR-arvo (Peak Signal to

Noise Ratio). PSNR kertoo erosta alkuperäisen ja uuden kuvan välillä ja se on määritelty

$$PSNR_{dB} = 10 \log_{10} \frac{(2^n - 1)^2}{MSE},$$

missä MSE on keskimääräinen neliöity virhe (Mean Squared Error) alkuperäisen kuvan ja uuden kuvan välillä. (Richardson (2010))

PSNR on helppo laskea ja antaa erään objektiivisen arvion videon laadusta. Menetelmällä on puutteensa, kuten se, että alkuperäistä kuvaa ei ole välttämättä saatavilla. Toisaalta, kuten monissa objektiivissa mittareissa, pelkkä PSNR arvo ei vastaa suoraan mitään subjektiivista arvoa. Yleisesti ottaen korkea PSNR arvo tarkoittaa hyvää laatua ja matala arvo huonoa. (Richardson (2010))

4 Rinnakkaislaskenta

Rinnakkaislaskennan (parallel computing) tavoite on parantaa laskennan suorituskykyä. Käsitteellisesti rinnakkaislaskentaa ei kannata sekoittaa samanaikaiseen laskentaan (concurrent computing). Akateemisessa mielessä jälkimmäinen keskittyy rinnakkaisen laskennan oikeellisuuteen, kun taas ensimmäinen keskittyy saamaan hajautetusta ja rinnakkaisesta laskennasta näkyviä hyötyjä laskentatehoon. (Grama et al. (2003), Ben.Ari (2006)) Tämä työ keskittyy rinnakkaisella laskennalla saavutettuihin hyötyihin videokoodauksen saralla.

4.1 Erilaisia rinnakkaisuuksia

Rinnakkaisuutta on nykypäivän tietokonejärjestelmissä monella tasolla. Nykyaikaisissa supertietokoneissa on jopa yli miljoona ydintä (Meuer et al. (2013)), tavallisia tietokoneita kerätään laskentaklustereiksi, tieteellisessä laskennassa hyödynnetään monenlaisia rinnakkaisia laskentamenetelmiä ja jopa Internetiä voidaan pitää eräänlaisena rinnakkaislaskennan alustana. Toisaalta suurten supertietokoneiden lisäksi rinnakkaisuus on tullut aivan tavallisten kuluttajatietokoneiden osaksi. Prosessorit ovat jo pitkään hyödyntäneet erilaisten laskentayksiköiden samanaikaista käyttöä laskentaa tehostaakseen (pipelining, liukuhihnaus). (Grama et al. (2003))

Yhteisiä eri tason rinnakkaisille ratkaisulle ovat niin hyödyt kuin haitatkin. Kaikki tavoittelevat lisäystä suorituskykyyn, mutta rinnakkaisuuden hallinta tuo laskentaan omia haasteitaan. Esimerkiksi liukuhihnaamisen hyödyt käyvät ilmi seuraavasta esimerkistä. Oletetaan, että tehdas tuottaa autoja. Kunkin auton valmistaminen kestää sata tuntia, joten valmistamalla yksi auto kerrallaan saadaan sadassa tunnissa yksi auto. Jos auton valmistus kuitenkin pilkotaan kymmeneen osaan, joita voi suorittaa rinnakkaisesti, ja joiden suoritus kestää kymmenen tuntia, voidaankin sadassa tunnissa tuottaa kymmenen autoa. Saavutettu hyöty triviaalissa esimerkissä on kymmenkertainen. (Grama et al. (2003)). Toisaalta samaa esimerkkiä voidaan hyödyntää ilmentämään liukuhihnaamisen vaikeuksia. Jos esimerkiksi kaksi peräkkäistä tehtävää olisivat auton ovien kiinnittäminen ja maalaaminen, niin on selvää, että autoa ei voi maalata ennen ovien kiinnittämistä. Esimerkiksi tällaiset riippuvuussuhteet aiheuttavat ongelmia rinnakkaislaskennalle ja niitä sekä muita haasteita varten täytyy kehittää hallintarakenteita.

Hallintarakenteita erilaisille rinnakkaisuuden muodoille on monia. Yksinekertaiseen liukuhihnaamiseen eräs ratkaisu on suoritettavien operaatioiden järjestäminen sellaiseen järjestykseen, että riippuvuussuhteet eivät aiheuta ongelmia. Toisaalta liukuhihnaa voidaan myös hidastaa, jolloin saavutettu laskentateho vähenee, mutta laskenta pysyy oikeana. Nämä ratkaisut kuulostavat yksinkertaisilta, mutta niiden toteutukseen ja vaikutuksiin

liittyy kuitenkin haasteita, joihin ei kuitenkaan tässä työssä syvennytä tarkemmin. (Grama et al. (2003))

Kun laskentayksiköitä on enemmän, tarvitaan monimutkaisempia hallintamekanismeja. Huomattavaa on kuitenkin, että usein rinnakkaisuutta on laskentayksikössä monella tasolla - esimerkiksi prosessoreita on monta, ja jokaisella prosessorilla on oma liukuhihnansa. Monimutkaisemmat hallintarakenteet voidaan jakaa karkeasti kahteen luokkaan sen perusteella, miten paljon laskennan hallintaa kullekin laskentayksikölle on jaettu. Jos hallinta on keskitetty, kyseessä on SIMD-arkkitehtuuri (Single Instruction stream, Multiple Data stream). SIMD-arkkitehtuurissa yksittäinen hallintayksikkö päättää, mitä kukin laskentayksikkö laskee. MIMD-arkkitehtuurissa (Multiple Instrucrion stream, Multiple Data stream) jokaisella laskentayksiköllä on oma hallintayksikkönsä. Konkreettisena esimerkkinä arkkitehtuurien erona voi pitää esimerkiksi sitä, että MIMD-arkkitehtuurissa jokainen laskentayksikkö voi suorittaa eri ohjelmia, kun SIMD-arkkitehtuurissa hallintayksikkö päättää, mitä ohjelmaa kaikki laskentayksiköt suorittavat. (Grama et al. (2003))

4.2 Rinnakkaisuuden peruskäsitteitä

Erilaisten rinnakkaisuuden muotojen lisäksi rinnakkaislaskenta voidaan jakaa kahteen tyyppiin sen perusteella, mihin rinnakkaisuus kohdistuu. Tehtävärinnakkaisessa laskennassa rinnakkain suoritetaan erilaisia tehtäviä - esimerkiksi saman ohjelman eri säikeitä. Datarinnakkaisessa ohjelmoinnissa taas rinnakkaisuus syntyy siitä, että operoidaan samaan aikaan eri datan osa-alueilla. Grama et al. (2003) Datarinnakkainen lähestymistapa sopii varsin hyvin videokoodauksen rinnakkaistamiseen - jos esimerkiksi tehdään DCT, voidaan kukin blokki käsitellä erikseen (blokit ovat riippumattomia toisistaan), joten saavutetut hyödyt laskenta-ajassa ovat huomattavat.

Rinnakkaisuuden kohteen lisäksi rinnakkaisilla kohteilla on erilaisia tapoja järjestää tiedon liikkuminen laskentayksiköiden välillä. Pääparadigmoja on kaksi, jaettu muisti ja viestinvälitys. Jaetun muistin mallissa laskentayksiköillä on yhteinen muisti, josta jokainen saa lukea ja kirjoittaa. Jotta yhteinen muisti pysyy puhtaana (kaksi laskentayksikköä ei lue ja/tai kirjoita samaan muistiosoitteeseen samaan aikaan), täytyy järjestelmällä olla keinot päättää, milloin mitäkin muistialuetta saa käsitellä. Erilaisia ratkaisuja tähän ongelmaan (mutual exclusion) on useita, kuten monitorit tai semaforit. Samojen muistialueiden käsittelyyn liittyy myös käsite kisatilanteista (race condition). Kisatilanteessa kaksi laskentayksikköä tavoittelee samaa muistialuetta, mutta valitun muistinsuojausmenetelmän pitäisi estää tämä. Kisatilanteet eivät varsinaisesti ole rinnakkaisten ohjelmien vikoja vaan syntyvät rinnakkaisohjelmoinnin sivutuotteena. (Ben.Ari (2006))

Viestinvälitysmenetelmän nimi kuvaa sitä hyvin. Jokaisella laskentayksiköllä on oma muistiavaruutensa, ja jos esimerkiksi yksiköiden välillä halutaan synkronoida, niin ne

vaihtavat viestejä. Menetelmä vaatii, että jokaisella laskentayksiköllä on tunniste, jolla sen voi erottaa muista. Tämä vaatimus ei koske jaetun muistin menetelmää. Luonnollisesti viestien välittämiseen tarvitaan myös jokin kanava niiden toimittamiseen. Viestien välittäminen on jaetun muistin käyttämistä tehottomampaa, mutta sitä käyttämällä on helpompi pitää yllä erilaisia laskentayksiköitä. Kaikkien käyttäessä samaa muistia yksiköiden tulee käsitellä muistia samalla tavalla, mutta viestejä välittäessä jokaisen yksikön täytyy vain täyttä viestinvälitysrajapinnan vaatimukset. (Grama et al. (2003))

Useasti on mainittu, että rinnakkaislaskennan tavoite on laskentatehon lisäys. Rinnakkaislaskennan laskentatehon lisäystä verrattuna peräkkäiseen laskentaan kuvaa Amdahlin laki, joka kuuluu

$$\frac{1}{r_s + \frac{r_p}{n}}, \tag{1}$$

missä $r_s + r_p = 1$ ja r_s kuva ei-rinnakkaistuvaa osaa ohjelmasta, r_p rinnakkaistuvaa osaa ja n laskentayksiköitä (Amdahl (1967)). Kaavasta voidaan päätellä, että laskentayksiköiden määrää suurentaessa laskentateho ei kasva äärettömyyksiin.

4.3 Rinnakkaisuuden haasteita

Rinnakkaistaminen tehostaa laskentaa, mutta rinnakkaistaminen ei tuo uudenlaisia haasteita tietokonejärjestelmien suunniteluun. Mainitut hallintarakenteet tuovat ylimääräisiä kustannuksia laskennan oheen, kuten viestintään liittyviä kustannuksia. Tietokoneiden tehokkuutta ei määrittele ainoastaan prosessorin tai prosessorien nopeus, vaan esimerkiksi muistin vasteaika ja kaistanleveys asettaa rajoja sille, kuinka paljon laskentaa voidaan suorittaa. Muistin hitautta voidaan kompensoida monilla keinoilla, kuten välimuisteilla (cache), monisäikeisyydellä (multithreading) tai ennakkohauilla (prefetching). Muistin hitaus ei ole yksinomaan rinnakkaislaskennan ongelma, mutta ongelma pahenee hallintakustannuksien ja monien laskentayksiköiden ongelmien kertautuessa. (Grama et al. (2003))

Puhtaasti rinnakkaisuuteen liittyviä ongelmia ovat esimerkiksi tyhjäkäynti (idling) ja turha laskeminen (excess computation). Tyhjäkäynnissä jotkin laskentayksiköt eivät suorita mitään laskentaa. Tämä saattaa johtua esimerkiksi siitä, että hallintajärjestelmä ei ole antanut laskentayksikölle laskettavaa, koska tarpeeksi tehtäviä ei ole. Tällöin resursseja hukataan. Turhaa laskentaa on esimerkiksi se, että useampi laskentayksikkö laskee samaa asiaa tahoillaan. Tällainen tilanne saattaa syntyä esimerkiksi silloin, kun rinnakkaislaskentaan valittu algoritmi ei ole tehtävään optimaalinen. Tilanne ei ole harvinainen, sillä monet tehokkaat peräkkäiset algoritmit käyttävät aiemmin laskettua tietoa hyväkseen.

Laskennan ollessa hajautettuna eri laskentayksiköille aiemmin lasketun tiedon hyödyntäminen on mahdotonta. (Grama et al. (2003))

4.4 Rinnakkaisten järjestelmien tehokkuuden mittaaminen ja skaalautuvuus

Aiemmin mainittiin Amdahlin laki, joka antaa karkean arvion ohjelman rinnakkaistamisen tuomasta laskentatehon nopeuden kasvusta. Tämä ei kuitenkaan ole ainoa tapa mitata rinnakkaisia järjestelmiä. Muita tässä käsiteltäviä tapoja ovat rinnakkaisuuden lisäkustannukset, ohjelman suoritusaika, laskennan tehokkuus, ja laskennan hinta. Kaikkia tuloksia voidaan verrata peräkkäisen ohjelman vastaaviin suorituksiin ja todeta, onko rinnakkaistaminen järkevää. (Grama et al. (2003))

Peräkkäisen ohjelman tapauksessa ohjelman suoritusaika on aika ohjelman suorituksen alkamisesta sen päättymiseen, jatkossa T_p. Rinnakkaisen ohjelman suoritusaika on aika rinnakkaisen ohjelman suorituksen alkamisesta viimeisen laskentayksikön laskennan loppumiseen, jatkossa T_r. (Grama et al. (2003))

Rinnakkaisuuden lisäkustannukset muodostuvat hallintajärjestelmän kuluista, viestien välittämisestä, synkronoinnista ja vastaavista toimista, jotka ovat välttämättömiä rinnakkaisen laskennan onnistumiseksi. Kuvatkoon p rinnakkaisen järjestelmän laskentayksiköitä, T_p yhden laskentayksikön suorittamaa laskentaa. Koko laskentaan suoritettu aika on siis pT_p. Olkoon T_h aika, joka on käytetty hyödylliseen laskentaan. Lisäkustannuksiin kulunut aika T_l olkoon siis $T_l = pT_p - T_h$. (Grama et al. (2003))

Laskentatehon nopeuden kasvu rinnakkaisessa on erityisen kiinnostava verrattuna vastaavaan peräkkäiseen ohjelmaan. Kuten mainittua, Amdahlin laki antaa jo arvion laskennan nopeuden kasvusta. Tässä tapauksessa vastaava peräkkäinen ohjelma ei välttämättä ratkaise ongelmaa samalla algoritmilla, kuin rinnakkainen ohjelma. Syy on turhan laskemisen yhteydessä mainittu joidenkin algoritmien heikko rinnakkaistuvuus. Yleensä vertailuun valitaan tehokkain peräkkäinen algoritmi. (Grama et al. (2003)) Laskentatehon nopeuden kasvun saa toki myös laskemalla suoritusaikojen erotuksen, mutta empiirinen tulos ei yksistään riitä osoittamaan rinnakkaista tai peräkkäistä toteutusta paremmaksi.

Ihannetilanteessa rinnakkaisen ohjelman tehokkuus olisi 100%, eli jokainen laskentayksikkö olisi koko ajan käytössä mahdollisimman suurella kapasiteetilla. Käytännössä tämä tilanne ei toteudu koskaan jo pelkästään rinnakkaisuudesta koituvien lisäkustannusten takia. Tehokkuus voidaan lausua yksinkertaisena yhtälönä

$$\frac{S}{p}, \tag{2}$$

missä S on laskennan nopeuden kasvu ja p laskentayksiköiden määrä. (Grama et al. (2003))

Rinnakkaislaskennan hinta määritellään rinnakkaisen ohjelman ajoajan ja käytettyjen laskentayksiköiden tuloksi. Yksittäisen laskentayksikön hinta on nopeimman peräkkäisen algoritmin suoritusaika. Jos rinnakkaisen algoritmin kasvu on asymptoottisesti sama kuin yksittäisen laskentayksikön algoritmin kasvu, rinnakkaista algoritmia sanotaan hintaoptimaaliseksi. (Grama et al. (2003))

5 Videokoodaus ja rinnakkaislaskenta

5.1 Rinnakkaisuuden hyödyt videokoodaukselle

5.2 Erilaiset kiihdytysalustat ja ohjelmistoratkaisut

6 Yhteenveto

Lähteet

Gene M. Amdahl. Validity of the single processor approach to achieving large scale computing capabilities. *AFIPS Conference Proceedings*, sivut 483–485, 1967.

Marios C. Angelides ja Harry Agius. *Handbook of MPEG Applications : Standards in Practice*. Wiley, Chichester, West Sussex, United Kingdom, 2011. ISBN 978-0-470-75507-0 (nid.), 978-0-470-97458-2 (elektr.). 551 s.

M. Ben.Ari. *Principles of Concurrent and Distributed Programming*. Pearson, Harlow, Essex, United Kingdom, toinen painos, 2006. ISBN 978-0-321-31283-9. 361 s.

Cisco. Ciscon ennustus mobiilidatan kehityksestä. `http://www.cisco.com/en/US/solutions/collateral/ns341/ns525/ns537/ns705/ns827/white_paper_c11-520862.html`, tammikuu 2013.

Ananth Grama, Anshul Gupta, George Karypis ja Vipin Kumar. *Introduction to Parallel Computing*. Pearson, Harlow, Essex, United Kingdom, toinen painos, 2003. ISBN 0-201-64865-2. 636 s.

Hans Meuer, Erich Strohmaier, Jack Dongarra ja Horst Simon. Listaus maailman supertietokoneista. `http://www.top500.org/`, maaliskuu 2013.

Iain Richardson. *H.264 Advanced Video Compression Standard*. Wiley, Chichester, West Sussex, United Kingdom, toinen painos, 2010. ISBN 978-0-470-51692-8 (nid.), 978-0-470-98928-9 (elektr.). 348 s.

YouTube. Youtube-statistiikkaa. `http://www.youtube.com/t/press_statistics`, tammikuu 2013.